

Сервис для защиты персональных данных при работе с LLM

Сервис предназначен для обнаружения и маскирования персональных данных в запросах к LLM и их восстановления в ответах модели.

llm-proxy

Исходная задача

Команды банка защищают ПД в запросах к LLM разными способами. Такие решения трудно переиспользовать и настраивать, а восстановление данных реализовано не везде.


Требуемое решение

Общий сервис маскирования ПД с обратимыми заменами, правилами для разных систем и возможностью добавлять новые типы.


Ориентиры ТЗ: качество 95%, 1000 запросов/с, ответ до 1 с, тексты до 100 000 токенов.

Взаимодействие с LLM


Запрос с ПД




Маскированный запрос



Ответ LLM с масками



Архитектура сервиса



Один сервис приложения и приватный Redis. Docker обеспечивает воспроизводимый запуск.

Обоснование выбора стека

Python + FastAPI	Обработка текста, строгая схема запроса и простой HTTP API.
Локальные правила поиска	Контроль границ и контекста без передачи ПД внешним моделям.
Redis + AES-GCM	Общее состояние для процессов, атомарное создание сессий и TTL.
Uvicorn + Docker	Несколько рабочих процессов и воспроизводимое развёртывание.
Prometheus + k6	Наблюдение за сервисом и измерение поведения под нагрузкой.

Данные, которые маскирует сервис

О человеке

ФИО
Дата рождения
Место рождения
Гражданство

Документы

Серия и номер паспорта
Орган выдачи
Код подразделения
Дата выдачи
Водительское
удостоверение
ИНН


Адрес и связь

Адрес и его части:
страна, индекс, город,
улица, дом, квартира
Телефон
Email

Банковские данные

Номер карты
CVV
ПИН-код
Имя держателя карты

Методика поиска ПД



Новые правила подключаются через реестр детекторов. HTTP-контракт и работа сессий сохраняются.

Маскирование и восстановление

Входные данные

Выходные данные

Маскирование запроса

Напишите на demo@example.com.

Напишите на <EMAIL_1>.

Восстановление ответа модели

Ответ отправлен на <EMAIL_1>.

Ответ отправлен на demo@example.com.

Один payload_id связывает запрос и ответ. Текст ответа сохраняется. Пример синтетический.

HTTP-контракт и политики систем

POST /process

Запрос

```
{  
  "payload": "строка для обработки",  
  "payload_id": "идентификатор"  
}
```

Ответ 200

```
{ "result": "обработанная строка" }
```


Настройки в YAML

Разрешение обращения
Категории ПД
Разрешение восстановления
Формат масок

Новый потребитель добавляется
через конфигурацию.

В текущем deployment система задана конфигурацией. Авторизации отправителя в публичном API нет.

Жизненный цикл сессии



Создать зашифрованную запись в Redis.
TTL после маскирования: 15 минут.
Вернуть маскированный текст.

Исходный текст: вернуть прежнюю маску.
Маска: вернуть исходную строку.
Ответ LLM: восстановить известные маски.

После восстановления TTL = 2 минуты. По истечении TTL Redis удаляет запись. Сроки настраиваются.

Логи, метрики и наблюдаемость

Логи обработки

Операция и код ответа
Типы и число найденных ПД
Время поиска и обращения к Redis

Метрики /metrics

Latency: время ответа
RPS: запросы в секунду
TPS: текстовые единицы в секунду
Ошибки, 429 и активные запросы

Исходный текст и значения ПД не включаются в логи и метрики.
Соответствия для восстановления хранятся в Redis под AES-GCM.

TPS использует разделение по пробелам. Это не токенизатор конкретной LLM.

Улучшение поиска в анкетах

Проверка: 200 синтетических анкет по 22 поля.

Всего 4400 значений, которые нужно закрыть маской правильного типа.

До доработки

1 902 из 4 400

43,23% полей полностью закрыты

Текущая версия

4 400 из 4 400

100% полей полностью закрыты

Добавили разбор полей по меткам, границы адресных компонентов и варианты дат. Контекстные правила не зависят только от контрольной суммы.

Результат относится к этой выборке анкет. Качество произвольного текста проверяется отдельно.

Проверка корректности

56 синтетических примеров с заранее заданными типами и границами ПД.
В набор входят разные форматы, пересечения и тексты без персональных данных.

Что проверяли	Результат на текущем наборе
Тип и точные границы найденных ПД	Все совпали с разметкой
Лишние срабатывания и пропуски	0 лишних находок, 0 пропусков
Маскирование и обратное восстановление	Исходная строка восстановлена в 56 из 56 примеров

Локальные тесты не подтверждают порог 95% на скрытом наборе AlfaSonar. Внешний результат открыт.

Результаты нагрузочных испытаний

Цель ТЗ: 1000 запросов/с, ориентир времени ответа до 1 с.

Профиль команды: 300 секунд после прогрева, маскирование и восстановление.

Метрика	Локально, 8 процессов	Railway
Успешных операций/с	≈1000	≈645
Время ответа для 95% операций	≤21,78 мс	≈10 с
Ошибки	0	≈33%

На локальном профиле цель достигнута. Публичный deployment выдержал короткий тест 100 запросов/с, но не прошёл профиль 1000 запросов/с.

Результат проекта

Реализовано

Сервис маскирования ПД с обратным восстановлением, настройками систем и зашифрованными сессиями. Локальные проверки подтверждают работу на тестовых наборах.

Остаётся подтвердить

Качество и совместимость в AlfaSonar, внешнюю проверку ZIP и целевую нагрузку на публичном сервере.

[Демонстрация API](#)

[Исходный код на GitHub](#)

Публичный API предназначен для синтетических данных. Соответствие стандартам ИБ банка не подтверждено.