

Защита персональных данных при работе с языковой моделью

Наш сервис скрывает сведения о человеке до отправки запроса
и восстанавливает их в полученном ответе.

llm-proxy


Задача и пять условий успеха

Для каждого требования показываем реализацию и способ проверки.

- | | | |
|-----------|----------------------|--|
| 01 | Встраивание | Один POST /process без обращения сервиса к модели |
| 02 | Все категории | Правила для 22 позиций ТЗ; качество свободного текста дорабатывается |
| 03 | Защита данных | Шифрование временной записи и журналы без исходных значений |
| 04 | Качество | Тесты и точное восстановление; официальный порог 95% не подтверждён |
| 05 | Нагрузка | 1000 операций/с локально; публичный сервер этот режим не выдержал |

Место сервиса в цепочке запросов

Приложение управляет обращением к модели. Наш сервис обрабатывает текст до и после него.




Возвращаемся тем же путём

Приложение передаёт ответ модели нашему сервису с прежним идентификатором. Сервис восстанавливает известные обозначения.

Архитектура: приложение и временная память

Одна служба обрабатывает оба направления. Общая временная запись доступна её рабочим процессам.



Журнал и метрики

Результат, типы и число найденных данных, длительность этапов. Исходные значения не записываются.

Redis доступен приложению по внутренней сети; языковую модель вызывает приложение.

Почему этот стек

Для задачи нужны быстрый локальный поиск, короткое хранение соответствий и простой HTTP-интерфейс.

Python + FastAPI

Правила работы с текстом и проверяемый HTTP-контракт

Несколько процессов Uvicorn

Обработка запросов одновременно; число процессов зависит от ресурсов

Redis + AES-GCM

Общая временная память, шифрование с проверкой целостности

Docker + Prometheus + k6

Повторяемое развёртывание, рабочие показатели и нагрузочные проверки

Поиск не вызывает сторонний сервис. База постоянного хранения и очередь сообщений задачу не упрощают.

Какие данные ищем

Правила предусмотрены для всех 22 обязательных позиций ТЗ. Надёжность вне размеченных анкет требует проверки.

О человеке	Документы	Адрес и связь	Банковские данные
ФИО Дата рождения Место рождения Гражданство	Паспорт Кем выдан Код подразделения Дата выдачи Водительские права ИНН	Страна · индекс · город Улица · дом · квартира Телефон Электронная почта	Номер карты Защитный код CVV ПИН-код Имя держателя

Наличие правила не означает 100% обнаружения в произвольном тексте; подробный список дан в приложении.

Как находим сведения о человеке

Сначала получаем кандидатов, затем проверяем их смысл и выбираем точные границы замены.

01 Форма записи

Телефон, почта, паспорт, карта и ИНН ищутся по виду и контрольным признакам.

02 Окружающие слова

ФИО, даты, адрес и защитные коды требуют подтверждающего контекста.

03 Пересечения

Из нескольких находок на одном месте оставляем подходящую по приоритету.

04 Границы

Замене подлежит найденное значение; соседний текст сохраняется.

«Дата рождения: 10.01.1990» требует защиты; обычную дату встречи правило не должно принимать за неё.

Как создаётся маска

Пример с вымышленными данными. Одно и то же значение получает одну маску внутри запроса.

Исходный текст

Напишите на ivan@example.com. Позвоните +7 916 123-45-67.
Повторите письмо на ivan@example.com.

После обработки

Напишите на <EMAIL_1>. Позвоните <PHONE_2>.
Повторите письмо на <EMAIL_1>.

Соответствие шифруется и хранится временно; замены в тексте применяются справа налево.

Два способа восстановить данные

Оба работают через POST /process с тем же идентификатором запроса.

А. Ранее выданная маска

Передали замаскированную строку без изменений. Сервис вернёт исходный запрос посимвольно.

Б. Новый ответ модели

«Письмо отправьте на <EMAIL_1>»
превращается в «Письмо отправьте на
ivan@example.com».

Неизвестные или изменённые моделью обозначения остаются в тексте. Соответствия из другого запроса или другой системы не используются.

Подключение и настройки систем

Запрос содержит ровно два поля. Ответ содержит только обработанный текст.

HTTP-интерфейс

```
POST /process
{ "payload": "...", "payload_id": "..." }
{ "result": "..." }
```

Настройки для приложения

Включено ли подключение
Какие категории данных защищать
Разрешено ли восстановление
Как выглядит обозначение

Сейчас активную систему выбирают при развёртывании. Публичный вызов не удостоверяет отправителя.

Что защищает временную запись

Без соответствий между масками и значениями восстановление было бы невозможно.

15 минут

Срок хранения после маскирования

2 минуты

Срок после успешного восстановления

Запись зашифрована AES-GCM. Ключ задаётся отдельно от кода. Redis не опубликован в интернете. В журнал не попадают исходный текст и значения найденных данных.

Сроки задаются конфигурацией. Полное соответствие внутренним правилам ИБ банка отдельно не подтверждалось.

Журналы и рабочие показатели

По запросу сохраняются безопасные признаки обработки; /metrics отдаёт агрегированные счётчики и задержки.

Одна запись в журнале

Операция: маскирование
Код ответа: 200
Найденные типы: email, phone
Число находок: 3
Поиск: 6,1 мс · Redis: 1,2 мс

Что можно измерить

Запросы в секунду и время ответа
Отказы, перегрузка и занятые процессы
Число находок по категориям
Скорость обработки текста и время Redis

Что показывают проверки качества

Внутренние тесты и официальная проверка используют разные данные и не заменяют друг друга.

4 400 / 4 400

заявленное покрытие размеченных полей
в 200 синтетических анкетах

F1 = 1,0

старый локальный набор из 46 примеров

Проверяем типы и границы, лишние срабатывания, маску и восстановление. Поиск данных в свободных формулировках исправляется и проходит отдельную регрессию; результат по анкетам не доказывает его качество.

Порог 95% на неизвестных данных организаторов пока не подтверждён.

Поведение при ошибках и большой нагрузке

Сервис не отдаёт исходные данные как запасной путь при сбое временной памяти.

01 Некорректный запрос

HTTP 422 без вывода исходного текста в журнал.

02 Перегрузка

HTTP 429 с указанием времени до повтора.

03 Проблема Redis

Контролируемая ошибка 503; обработка закрывается.

04 Повтор запроса

Прежняя маска возвращается по тому же идентификатору.

Ограничение 8 млн символов; 100 тыс. условных токенов тестировались локально отдельно.

Скорость зависит от среды запуска

Пятиминутный профиль 1000 операций в секунду: полный локальный прогон прошёл, публичный нет.

Показатель	Локальный компьютер	Railway
Успешно за 300 с	300 001	193 444
Успешно в секунду	≈1000	≈645
Время ответа p95	21,78 мс	≈10 с
Ошибки	0	≈33%

Короткий прогон Railway: 100 операций/с, 30 с, без ошибок. Локально: 8 процессов; в Railway ресурс ограничен.

Дополнительные возможности: фактическое состояние

Бонусные пункты показываем отдельно от обязательных требований.

Два формата обозначений для систем

Реализовано

Новые типы через дополнительные правила

Предусмотрено в устройстве

Отдельная токенизация / синтетические значения

Не реализованы

2000 операций/с до 1 секунды

Не подтверждено

Новые виды удостоверений и составные правила

Не подтверждены

Сводка по требованиям

Состояние отражает проверки команды на момент подготовки материалов.

Требование	Что сделано	Что подтверждено
Интерфейс и восстановление	POST /process, два сценария	Локальные и сквозные проверки
22 категории данных	Правила предусмотрены	Качество на неизвестных данных открыто
Разные системы и доступ	Политики из конфигурации	Публичная авторизация отсутствует
Журналы и защита	Метрики, шифрование, срок	Локальные тесты и проверка среды
95% качества	Внутренний набор пройден	Официальный прогон открыт
1000 операций/с	Достигнуто локально	Railway не прошёл

Демонстрация и материалы

Запрос с вымышленными данными доступен через публичный адрес.

Публичный адрес

<https://llm-proxy-production-84c7.up.railway.app>

Исходный код

<https://github.com/rp-alpha-vibe/llm-proxy>

Открытые проверки: официальный результат качества и допуск тестера. Нагрузочный профиль на публичном сервере пока не пройден.

Публичная демонстрация предназначена только для вымышленных данных.

Приложение: все 22 категории

Каждая строка адреса из задания учитывается отдельно.

1 ФИО	9 Водительское удостоверение	
2 Дата рождения	10 ИНН	17 Телефон
3 Место рождения	11 Страна	18 Электронная почта
4 Гражданство	12 Индекс	19 Номер карты
5 Паспорт	13 Город	20 CVV
6 Орган выдачи	14 Улица	21 ПИН-код
7 Код подразделения	15 Дом	22 Имя держателя карты
8 Дата выдачи	16 Квартира	

Правила предусмотрены для всех позиций; общая доля корректного обнаружения требует отдельной проверки.

Приложение: настройка нового приложения

Добавление типового потребителя не требует менять алгоритм поиска.

1. Добавить систему в `config/systems.example.yaml`.
2. Указать `enabled` и список защищаемых категорий.
3. Разрешить либо запретить восстановление.
4. Выбрать формат обозначений.
5. Установить идентификатор активной системы при запуске.

Отдельную проверку личности вызывающего приложения текущий публичный интерфейс не выполняет.

Приложение: как измеряли нагрузку

Сравнивать среды можно только вместе с условиями испытаний.

Профиль: 300 секунд после прогрева, целевая подача 1000 операций/с. Одна операция означает отдельное маскирование или восстановление. Успешный повтор не скрывает ошибку предыдущей попытки.

Локальный компьютер

8 рабочих процессов; 300 001 успешная операция; ошибок и 429 нет.

Публичный Railway

193 444 успешных операций; 76 483 ответа 429; 10 019 пропущенных итераций.